DRZEWA DECYZYJNE

LAB 3 – Uczenie bez nadzoru

Zadanie 1. (1 pkt.)

Zbiór danych: http://archive.ics.uci.edu/ml/machine-learning-databases/00396/

Dane dotyczące transakcji różnych produktów na przestrzeni 51-tygodni zawierają zarówno wartości oryginalne jak i znormalizowane.

Zadanie 2. (3 pkt.)

Wykonaj analizę skupień danych dla następujących algorytmów:

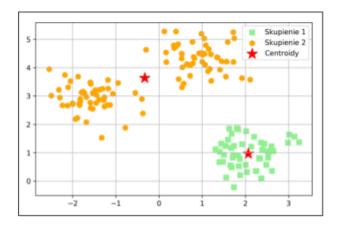
- K-MEANS
- K-MEANS++
- *K-MEDIOD

W wyniku analizy skupień dodaj do każdej próbki kategorię odpowiadającą przypisanemu klastrowi (zakładamy kategorie całkowite: 1,2,3,....).

W zaimplementowanych algorytmach jako argument użytkownik może wprowadzić liczbę klastrów (domyślnie 5).

Przedstaw graficznie (na wspólnym wykresie) wyniki analizy skupień dla w/w metod:

- Każdy klaster powinien być zaprezentowany unikatowym kolorem oraz stylem punktu (np. czerwone kółko, niebieski kwadrat, itp).
- Dla każdego klastra wyznacz centrum klastra.



Wynikiem działania algorytmu powinien być zbiór danych z etykietami klas przypisanymi na podstawie klasteryzacji.

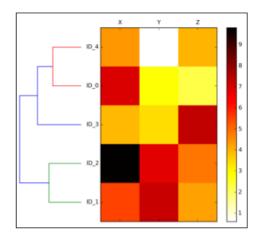
Zadanie 3. (3 pkt.)

Wykonaj klasteryzacje dla tego samego zbioru danych na podstawie algorytmów:

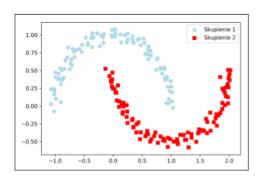
- AgglomerativeClustering z dowolnym typem klasteryzacji, typem wiązania oraz metryką odległości
- DBSCAN z domyślnymi wartościami argumentów

Zaprezentuj graficznie (na jednym wykresie) wyniki klasteryzacji:

Klasteryzacja aglomeracyjna – dendrogram + mapa cieplna



• DBSCAN – wykres z oznaczeniem klastrów (kolor + symbol)



W wyniku analizy skupień dodaj do każdej próbki kategorię odpowiadającą przypisanemu klastrowi (zakładamy kategorie całkowite: 1,2,3,....).

Wynikiem działania algorytmu powinien być zbiór danych z etykietami klas przypisanymi na podstawie klasteryzacji.

Zadanie 4. (3 pkt.)

Korzystając z miary silhouette, a dokładnie średniej miary silhouette dla wszystkich klastrów oblicz i zaprezentuj graficznie optymalne liczby klastrów dla każdego z analizowanych algorytmów w zakresie od 2 do 15 klastrów.

Przykład zobrazowania:

